显示屏缺陷检测与可控缺陷生成

阶段研究成果汇报

整理日期：2026 年 11 月 9 日

覆盖范围：2026 年 10 月 9 日—11 月 5 日

本材料在私人设备上使用公开文献、公开数据与公开代码完成，限个人学习与非商业研究；公司内部材料保持隔离。文中所有数字均抄自已封存报告与其核验记录，本次整理没有重算任何指标、没有加载模型、没有训练或生成。

本文档为阶段研究成果汇报，不构成生产验证结论

目　录

摘要 . . . 3
一、问题与目标 . . . 4
1.1 真实弱缺陷为什么难 . . . 4
1.2 目标设定 . . . 4
1.3 与开源工作的关系 . . . 4
二、技术路线 . . . 4
2.1 参数化外观模拟与标签体系 . . . 4
2.2 评价管线 . . . 5
2.3 检测模型与数据角色 . . . 5
2.4 检测器响应测量与 SEMU 代理刻度 . . . 5
2.5 工程约束 . . . 6
三、成果一：模拟控制与标签核验 . . . 6
3.1 首轮 24 个预定请求 . . . 6
3.2 共享留出 480 请求 . . . 7
四、成果二：模拟域适配（G0 / G1） . . . 8
4.1 设置 . . . 8
4.2 结果 . . . 8
4.3 能说什么，不能说什么 . . . 9
五、成果三：真实工业数据的两轮配对训练 . . . 9
5.1 随机初始化轮（GN 监督分割） . . . 9
5.2 预训练单头轮（ImageNet ResNet18 + SMP） . . . 9
5.3 两轮合起来说明什么 . . . 11
六、成果四：公开基线与评价管线给出的反例 . . . 12
七、成果五：检测器响应测量（当前最完整的一条链） . . . 12
7.1 为什么要做这一层 . . . 12
7.2 已完成的测量 . . . 12
7.3 全量响应 . . . 13
7.4 这组数字能支撑什么 . . . 13
八、成果六：统计刻度与留出状态 . . . 14
8.1 六个候选表示已拟合完成 . . . 14
8.2 留出状态 . . . 14
九、没有跑通或主动暂停的分支 . . . 15
十、工程资产 . . . 15
十一、边界与不可引用表述 . . . 16
11.1 每条结论必须带的边界 . . . 16
11.2 明确撤回的表述 . . . 16
11.3 三个容易混的 0.5 . . . 16
十二、结论与下一步 . . . 16
12.1 三条结论 . . . 16
12.2 未完成项 . . . 17
12.3 两条分叉，取决于投入方向 . . . 17
12.4 三个待确认的问题 . . . 17
附录 A　成果台账 . . . 18
附录 B　数字来源 . . . 18

摘要

这个项目围绕一个具体问题展开：**真实弱缺陷样本稀少，能不能用可控的模拟缺陷补上，并且说清楚补上之后到底发生了什么。**

三条线，结论强度完全不同：

第一条线——做了一个能用的模拟器。 参数化控制位置、范围、形状、大小、方向、亮暗与强度，输出不只是“看起来像缺陷的图”，而是可核对的三层信息：请求区域、实际改动量、有效标签。24 个预定控制请求全部有效、区域外像素零改动；480 个共享留出请求中 460 个有效、20 个无效，无效样本和原因全部保留。这是目前最可以直接交出去的部分。

第二条线——在真实工业数据上做了两轮配对训练，没有拿到稳定收益。 KolektorSDD2 固定 5 张真实异常的严苛条件下，三对初始化各训练两个模型：随机初始化轮像素 AP 平均 +1.75 个百分点（样本 SD 3.40），预训练单头轮 +0.78 个百分点（配对 SD 1.28）。两轮方向都不一致，个别工作点有误报或漏检代价。按 n=3 的离散度算，要检出 1 个百分点的效应大约需要 13 对实验——两轮都没到这个设计强度。**结论是“平均小正但不稳定”，不是“合成有效”，也不是“合成无效”。**

第三条线——把问题从“能不能提分”换成“这个检测器到底对什么有反应”。 在固定 PatchCore（tau=1.852951）上，用 60 个背景 × 9 种几何 × 7 档幅度 × 亮暗两向共 7560 个数字刺激做全量响应测量：非零刺激的空间联合报警率 42.88%，幅度 0.001 / 0.002 时为 0，0.032 时 89.35%，0.064 时 95.28%；315 个零变化对照的报警与配对分数差精确为 0。这条链已完整跑通并封存，**是当前证据最干净的一组数字**，但它的边界同样明确：固定刺激网格、60 个背景、一个检测器，不是 7560 个独立真实缺陷。

三条线的共同产物不是“检测提升方案”，而是**一套可复用的可控输入工具、一条能区分定位 / 排序 / 报警代价的评价管线，以及一批能追溯、能反驳、也敢撤回的测量结果**。这一点比任何单个 AP 数字都重要。

一、问题与目标

1.1 真实弱缺陷为什么难

显示屏的 Mura（亮度不均）与线状缺陷有三个现实困难，直接决定了实验设计：

1. **样本少。** 公开数据里真实异常往往只有几张到几十张（本项目用的 KSDD2 严格条件只有 5 张 R5），训练时反复曝光同一批异常，模型容易记住这几张而不是学会这一类。
2. **位置和强度不可控。** 真实缺陷长在哪里、有多强，无法按实验需要指定，因此“缺陷弱到什么程度会漏”“多大面积才检得出”这类问题无法用真实样本系统回答。
3. **评价口径容易混。** 像素定位、整图排序、固定阈值下的报警代价是三个不同的问题。用一个“准确率”或一个高分概括，会掩盖真正的失败模式。

1.2 目标设定

用户在第一周就把优先级定清楚了：**可控模拟为主，检测提升为加分项。**

这意味着项目的验收标准不是“检测指标必须涨”，而是：

- 能不能按指定条件生成，并且能核对“实际改了什么”；
- 模拟出来的东西拿去训练，会发生什么，能不能讲清楚；
- 讲不清楚的地方，能不能定位到是数据、测量还是模型的问题。

1.3 与开源工作的关系

PatchCore、DRAEM、SMP 单头 U-Net、SSN 均来自已有开源实现，ImageNet 骨干为第三方权重。本项目的工作是**适配、复现、评测与边界界定**，不是发明这些方法。这一点在所有对外材料中保持一致的表述。

二、技术路线

2.1 参数化外观模拟与标签体系

模拟器不做神经生成，只做可解释的编码 RGB 扰动：

- **两类外观**：块状亮度不均（Mura 式）、线状亮度扰动；亮 / 暗作为属性单独记录。
- **几何**：圆 / 椭圆 / 多边形、直线 / 折线；位置、尺寸、方向、角度全部可请求。
- **强度**：有符号幅度，加到背景上，落盘为 8 位 PNG。

关键在于标签不止一层：

标签	含义	用途
M_roi	请求允许变化的区域	记录“想改哪里”
alpha	连续扰动场	记录“怎么改”
D	输入输出最大 RGB 通道绝对差	记录“实际改了多少”
M_eff	D 严格大于 1/255 的位置	有效标签（本项目规则）
M_png	PNG 码值差大于 0 的位置	展示口径变化

为什么要分这么多层：因为“生成成功”“标签有效”“看起来逼真”是三件不同的事。前两层可以核验，第三层需要专家判断，项目从不把前两层当作第三层的证据。1/255 是本项目的标签门槛，不是 float32 的表示极限，也不是可见性阈值。

2.2 评价管线

三件事分开做，不合并成一个数：

- **像素定位**：全局像素平均精确率（AP），用双 uint32 计数表精确处理同分数像素，float64 累计，与 sklearn 交叉核验过。
- **整图排序**：整图 AUROC，与阈值无关。
- **报警代价**：固定 tau（正常校准得到，q0.95 / linear / 严格大于），报告 TP / FN / FP / TN。

推理侧统一为原生分辨率窗口（256 窗、stride 128、去重尾窗），补边像素不参与损失和指标，重叠区概率按 FP32 等权平均拼回。这套管线保证了“同一个模型换评价口径后数字仍然可比”。

2.3 检测模型与数据角色

模型	角色	说明
PatchCore	主检测器（无监督）	正常特征库，不用任何异常样本
DRAEM-A / B	对照（有监督）	作者式 Perlin / DTD 合成 + 真实异常
G0 / G1	模拟域对照（有监督）	同一 DRAEM 结构，G1 用本项目参数化模拟
SMP 单头 U-Net	预训练基线	ImageNet ResNet18 编码器
SSN	严格 R5 基线	预训练分割 + 分类双头

KSDD2 的角色划分固定：R5 真实异常（唯一监督）、N1885 正常训练、Q200 正常校准、U241 不用、E1004 评价。评价集是同一批 1004 张真实图（110 异常 / 894 正常），每模型 146,411,528 个原生像素、486,461 个阳性像素。**E 在历史工作中已被观察过，后续实验只能称“探索性解释”，不能称独立测试。**

2.4 检测器响应测量与 SEMU 代理刻度

这是后期新增的一条线，也是方法上最不一样的一条。

前面所有实验都在比较“两个训练结果的差异”，而训练方差往往比效应大。响应测量换了问法：**固定一个已训练好的检测器，喂给它条件已知的刺激，看它在什么条件下报警、峰落在哪里。**

三个关键设定：

- **响应定义**：整图原生分数 > 自身 tau（H_alarm），并且热图全局首个峰落在指定的几何区域 M_geo 内（H_joint）。联合报警不是分割准确率，也不是因果检出。
- **刻度**：沿用 SEMU 代理（对比度 / 面积 / 背景的组合量），主 k=0.4，另设 0.2 / 0.8 作敏感性；不在这里重推物理单位。
- **预算**：60 个拟合背景 ×126 请求 = 7560；另有 60 个留出背景同规模（D_hold60）。两批互斥。

2.5 工程约束

- **所有训练与含参数更新的运行由用户手动启动**，助手只准备代码、配置、命令并核验结果；
- 冻结成果（权重、阈值、指标、图件、失败现场）一律不改；
- 每个分支都有独立的只读核验入口（verify-*），只核身份、分母与完整性，不重算指标；
- 环境隔离：`.venv`（CPU 指标）、`.venv-pretrained-seg`（Torch+SMP）、`.venv-ssn` 互不污染。

三、成果一：模拟控制与标签核验

3.1 首轮 24 个预定请求

12 对几何变化，Mura 式与线状各 12 例，共用 4 张背景。

- **24/24 有效**；
- 区域外 float 残差与 PNG 码值变化均为 0；
- 8 项预定无效条件（越界、退化、饱和等）全部被拒绝。

这说明“指定条件 → 实际改动 → 标签”这条链在预定样例上是闭合的，但**不证明任意图像上都能生成有效或逼真的缺陷**。

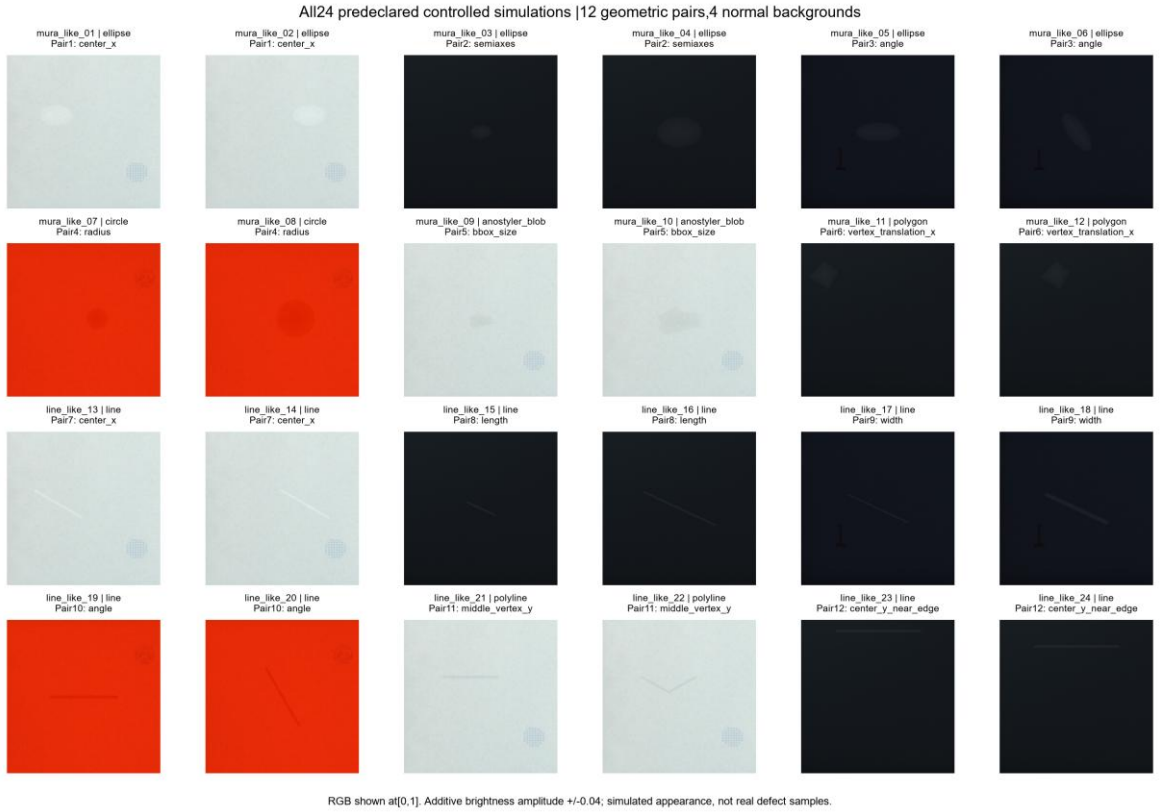


图 1　全部 24 个预定控制请求（固定原顺序，未重生成、未挑选）。位置、形状、大小、方向的变化用于展示控制能力；24 个变体不代表 24 张独立背景。

3.2 共享留出 480 请求

20 张按规则留出的背景、6 个模板、亮暗 × 幅度 0.04 / 0.02，共 480 个请求，每个只生成一次。

项	数量
请求总数	480
有效	460
无效（原因保留）	20
每强度有效异常	230
共用正常	20

无效样本不重试、不改判为正常、不补数。每强度评价 20 正常 + 230 有效异常，像素分母 16,384,000、阳性 219,208。

这一层的意义：把“按参数生成”推进到“实际变化可核验、无效样本可识别”。有效率不是检测准确率，两者不能混谈。

四、成果二：模拟域适配（G0 / G1）

4.1 设置

G0、G1 使用同一 DRAEM 检测结构，各完成 10000 步正式训练，各自用最终权重与 Q_cal40 冻结阈值（G0 0.612454，G1 0.715590）。区别只有一个：G0 用作者式 Perlin / DTD 合成，G1 用本项目参数化可控模拟。正常背景来自固定 N_gen80。

4.2 结果

共享模拟评价	G0 全局像素 AP	G1 全局像素 AP	G0 TP/230	G1 TP/230
主强度 0.04	55.1564%	99.0349%	69	224
弱强度 0.02	11.7830%	93.0047%	10	208

同 20 正常上的误报：G0 2/20、G1 1/20。

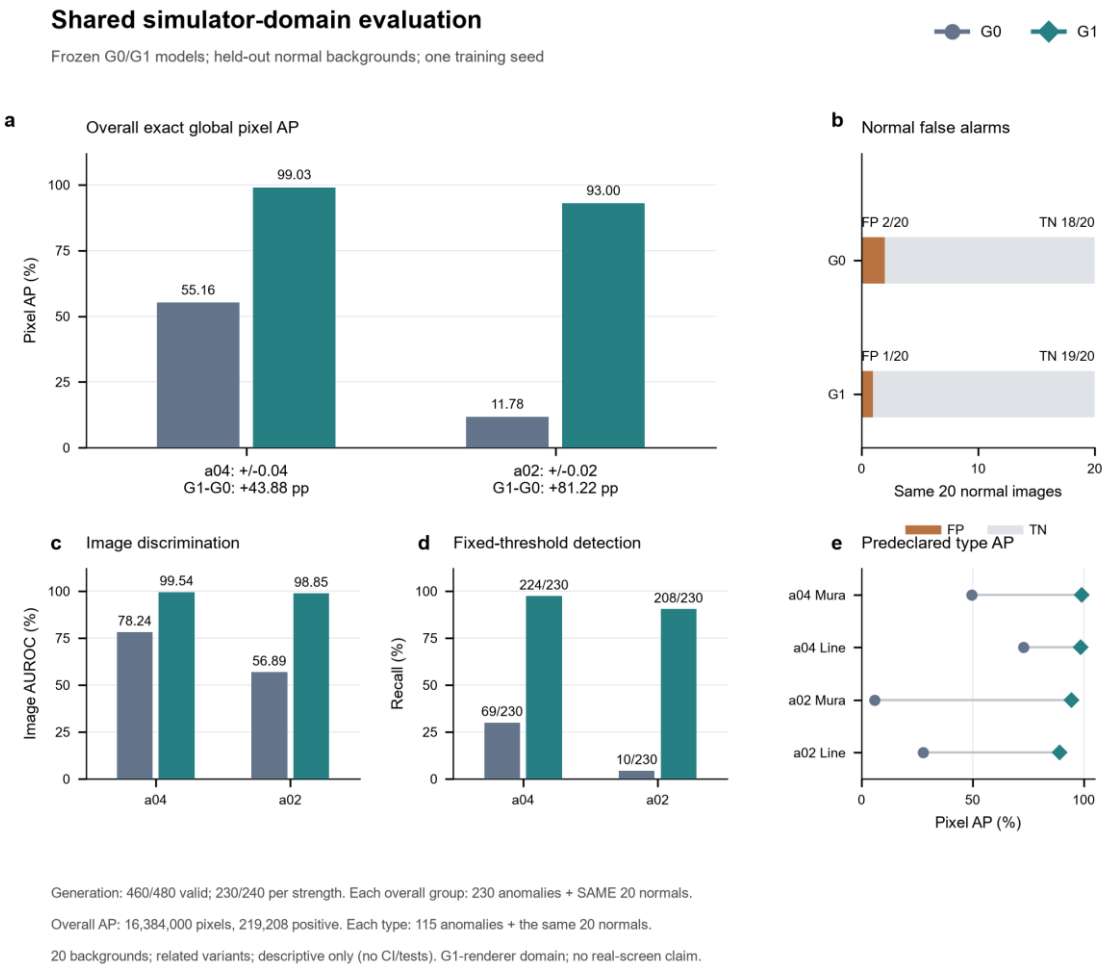


图 2　共享渲染器留出上的两强度指标（G0 对 G1）。同一批 20 个留出背景、同一评价口径，直接引用冻结结果。

4.3 能说什么，不能说什么

能说：模型可以适应该渲染器域内的刺激，特别是在与 G1 训练机制相近的评价条件下；G1 对弱强度刺激的保持能力明显好于 G0（93.0% 对 11.8%）。

不能说：99.0349% 不是真实屏幕效果、不是生成逼真度、也不是总体泛化能力。原因有三：20 个背景虽按规则留出但所有变体相关；生成器与评价池同源；只有一个训练种子。这四个 99% 级数字（特征域 / 样本拟合 / 生成器域 / 原生描述）口径完全不同，**彼此不能相减，也不能横向比较**。

五、成果三：真实工业数据的两轮配对训练

这是全项目最费资源、也最能体现实验设计的部分。两轮都采用同一模型内的 A / B 配对（同一初始化、同一数据请求顺序，只改一个槽位），三对初始化。

5.1 随机初始化轮（GN 监督分割）

每对两模型各 10000 更新，真实异常曝光均为 5000 次；A 另有正常 5000 次，B 用 2500 次合成异常替代其中 2500 次正常。三个初始化种子为 2026101903 / 04 / 05，下表按其末两位简称 03 / 04 / 05。

配对	A 像素 AP	B 像素 AP	B−A（百分点）	B−A FP	B−A FN
03	35.2649%	36.2359%	+0.9710	−28	+1
04	32.7732%	38.2476%	+5.4744	−18	−3
05	36.4531%	35.2615%	−1.1916	−11	−3
均值 / 样本 SD			**+1.7513 / 3.4008**		

三对误报均减少（28 / 18 / 11 张），但 03 种子漏检增加 1 张（FN 37→38，TP 73→72）；04、05 的 FN 各减少 3 张。05 同时出现像素 AP 下降、整图 AUROC 提高、阈值错误计数改善——三类指标不能互相替代。

5.2 预训练单头轮（ImageNet ResNet18 + SMP）

A：真实异常 5000 / 正常 5000；B：真实异常 2500 / 合成 2500 / 正常 5000，图像级正负总曝光匹配。合成材料固定复用旧 03 池 ordinal 0—2499，三对共用，未按旧 E 效果挑池。三个种子为 2026102301 / 02 / 03，下表简称 01 / 02 / 03。

配对	A 像素 AP	B 像素 AP	B−A（百分点）	B−A FN	B−A FP
01	45.39331802%	44.96507568%	−0.42824234	−7	−1
02	38.83696935%	40.94975543%	+2.11278608	−11	−17
03	35.71167980%	36.35833030%	+0.64665050	−2	+9
均值 / 样本 SD			**+0.77706475 / 1.27552431**		

03 的整图 AUROC 同时下降 1.238 个百分点。

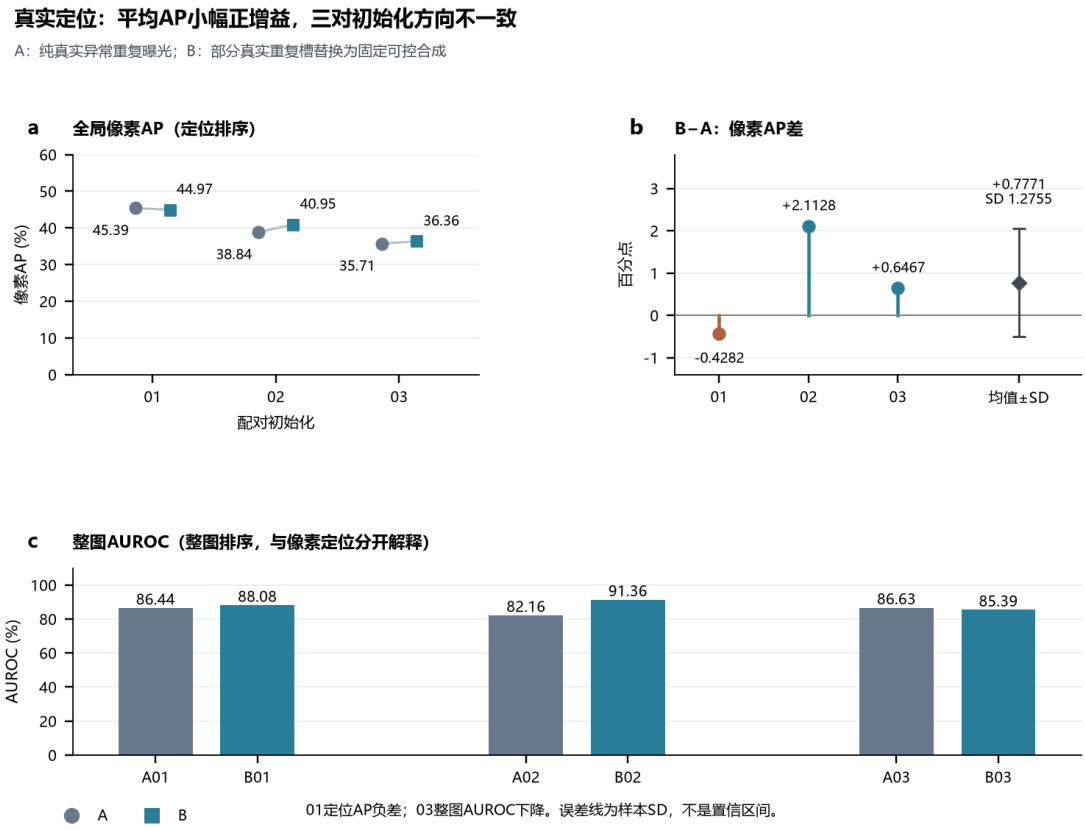


图 3　三对配对的 AP、差值及六个模型的整图 AUROC。01 的负 AP 差与 03 的 AUROC 下降均完整展示，未筛选。

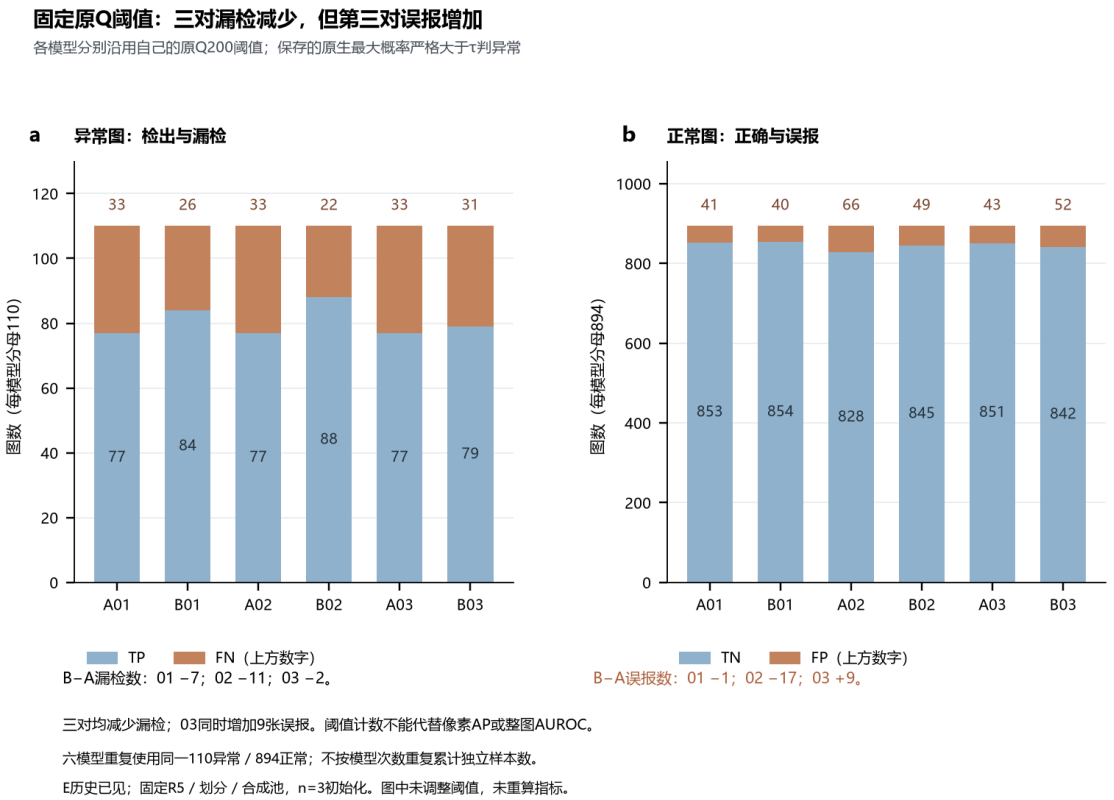


图 4　六个模型在各自 Q200 冻结阈值下的 TP / FN / FP / TN。定位改善与报警代价是两件事，必须分开看。

5.3 两轮合起来说明什么

- 平均值都为正，所以**不能说“合成没有作用”**；
- 方向不一致、存在误报和漏检代价，所以**不能说“稳定提升真实检测”**；
- 按 n=3、配对 SD 1.28 计算，检出 1 个百分点约需 13 对；两轮都没到这个强度，所以**当前结论是“效应不可检测”，不是“效应为零”**。

另外必须承认混杂：B 臂同时改变了真实异常曝光、阳性像素量与背景组成，三对也不能当三个独立数据集。**这一轮测到的是“训练组成效应”，不是“模拟外观质量效应”。**

六、成果四：公开基线与评价管线给出的反例

这一部分的价值不在分数，而在**证明单个漂亮指标会骗人**。

实验	主要数字	这条数字掩盖了什么
leather PatchCore	整图 AUROC 1.0，异常检出 92/92	正常误报 21/32；像素 AP 仅 46.70%
AnoLCD PatchCore	像素 AP 85.83%，AUROC 90.86%，TP635 / FN115 / FP45 / TN305	cylinder 占阳性像素约 97.8%，小缺陷定位被大面积掩盖
AnoLCD DRAEM-A / B	像素 AP 13.98% / 15.64%，AUROC 49.95% / 50.37%	AUROC 与随机排序无异，说明该配置未收敛；B−A 的 +1.66pt 不构成方法有效性证据
正常校准研究	m=8/16/32/48 的阈值 5—95% 跨度 0.482 / 0.258 / 0.069 / 0	全池恒定是有限池构造性质，不是总体稳定性；H 上 FP 均为 4/48
单头基线	像素 AP 43.65%，AUROC 85.72%，TP81 / FN29 / FP52 / TN842	技术完整但未达应用要求，也不能与旧架构相减证明预训练的作用
SSN 严格 R5	特征 AP 99.9156%，逐例最低 99.6481%	21 张训练图同池拟合；分类严格 >0.5 时 FP 10/16，联合 gate = false

SSN 这一项值得单独说明：它不是“模型不行”，而是**验收结构不可通过**——固定的 `sigmoid > 0.5` 是本项目自加的工程门槛，与 focal loss 未校准的输出不兼容；而 gate 又是正式训练的入场券，形成闭环。分类 BN 统计来源敏感性诊断显示翻转是双向的（FP 10→8），即使修好也仍然不过。原 false 保留不改写。

七、成果五：检测器响应测量（当前最完整的一条链）

7.1 为什么要做这一层

前面所有对照实验都在比“两个训练结果”，而训练方差往往大于效应。响应测量把方差大的因素固定住：**同一个模型、同一批背景、只改刺激。**

7.2 已完成的测量

固定 PatchCore（原作者 WRN50-2、本地 ImageNet V1、N80 特征库、原预处理与原 tau=1.852951288223265），对 60 个拟合背景施加 9 种几何 × 7 档幅度 × 亮暗两向的刺激。

项	数量
背景	60（不是 7560）
数字请求	7560
基线 + 请求引用	7620
唯一 float RGB / 热图	7305
零实际变化 / 非零	315 / 7245
弱非零且旧 M_eff 为空	2070
实际新增模型前向	7303（另 2 份复用，1 次作者占位探测另计）

实际评分事务耗时 11,434 秒（约 190 分钟），GPU 峰值分配 366.8 MiB。

7.3 全量响应

请求状态	分母	整图报警	空间联合报警	联合报警率
全部名义请求	7560	3564	3107	41.10%
非零实际变化	7245	3564	3107	42.88%
零实际变化	315	0	0	0.00%
弱非零且 M_eff 为空	2070	180	0	0.00%
M_eff 非空	5175	3384	3107	60.04%

按幅度（每档 1080 请求，同 60 背景 × 9 几何 × 2 方向）：

名义幅度	整图报警	联合报警	联合报警率
0.001	90	0	0.00%
0.002	90	0	0.00%
0.004	121	31	2.87%
0.008	471	382	35.37%
0.016	769	700	64.81%
0.032	988	965	89.35%
0.064	1035	1029	95.28%

按几何（每档 840 请求）：

几何	联合报警率	几何	联合报警率
r04_circle	28.21%	r08_ellipse_d	46.67%
r04_ellipse_h	32.14%	r12_circle	45.48%
r04_ellipse_d	36.19%	r12_ellipse_h	45.95%
r08_circle	44.88%	r12_ellipse_d	48.21%
r08_ellipse_h	42.14%		

基线：60 个背景中 5 个整图报警（5/60），这 5 个背景的 540 个固定区域视图联合报警 0/540；540 视图的整图报警 45/540 是同一批 5 个背景各重复 9 次，**不能累加成 45 个独立误报**。

亮暗：亮 37.59%、暗 44.60%，但亮档含 315 个零变化请求、两向实际对比度与背景条件也不同，**不能作为亮暗敏感性的单因素因果判断**。

7.4 这组数字能支撑什么

能支撑的三点：

1. **响应是条件相关的，不是随机的。** 幅度 0.001 / 0.002 联合报警为 0，0.032 达 89.35%，0.064 达 95.28%——同一模型、同一背景集上形成了单调的剂量—响应。
2. **负对照干净。** 315 个零实际变化请求的报警与配对分数差精确为 0，说明配对读数和报警判定没有被实现细节污染。
3. **“看不见的变化”确实没有空间响应。** 2070 个 float 有变化但 M_eff 为空的请求，整图报警 180 条（多为背景本身已报警），空间联合报警 0 条。这条给后续“阈值以下改动是否有用”提供了直接反例。

不能支撑的：

- 不是 7560 个独立真实缺陷的检出率，是固定刺激网格上的条件响应；
- 不是 SEMU 代理有效性的证明——那要等留出背景比较（见下一节）；
- 不是分割准确率，也不是“注入即检出”的因果证明；
- 60 个背景的物理采集独立性未知，工作 RGB 去重不等于物理面板独立。

八、成果六：统计刻度与留出状态

8.1 六个候选表示已拟合完成

在 7560 行（60 背景 × 126 共同可定义请求）上，背景等权二项负对数似然 + 岭惩罚，六个候选全部收敛：

候选	非截距特征	系数数	惩罚目标	迭代
C-only	log1p(C_pair_pct)	2	0.315106761025	9
C+area	上 + log(A_geo) + 交互	4	0.281453626838	13
SEMU-only k=0.4	log1p(SEMU_proxy)	2	0.305948119935	9
C+area+context	上 + log(Lb) + 背景 std + 形态指示	9	0.212297225496	19
SEMU-only k=0.2	log1p(SEMU_proxy)	2	0.305999327087	9
SEMU-only k=0.8	log1p(SEMU_proxy)	2	0.306949171088	9

共同常量参照 p0 = 0.4109788359788335。

必须说清楚：这些是拟合诊断（D_fit 惩罚目标），不是留出成绩。目标最小不等于泛化最好，不能据 0.2123 认定含背景的模型能预测新背景。标准化系数不是物理阈值。

8.2 留出状态

D_hold60 的评分准备已完成并封存：7620 引用、7116 个唯一 float RGB（与既有 300 张正常、D_fit 7305 张的内容重合为 0），504 个零变化、7056 个非零、其中 2016 个弱非零。**实际评分（run）尚未执行**，按既有平均耗时线性参考约 3.1 小时。

所以现在能回答的是“响应长什么样”，还答不了“SEMU 这个刻度能不能预测新背景”。

九、没有跑通或主动暂停的分支

失败与暂停同样要写进材料，否则下一次会在同一个地方再撞一遍。

分支	状态	卡在哪里
真实参考驱动生成 v1/v2/v3	暂停，生成请求 0	同域背景素材不足：v1 暗底参考配亮底点阵背景；v2 两张背景含刻度与规律圆点；v3 收紧到 24 个局部位置仅 3 个通过。**瓶颈在素材，不在渲染算法**
参考条件接口 Demo	停在 CPU 输入与静态资源准备	模型资源未定位，安装与实际兼容未完成，没有神经生成输出
SSN 严格 R5	结论冻结：gate=false	特征 AP 99.9156% 是同池拟合；分类 FP 10/16 未过
Mura 检测器能力说明（50 对真实 Mura）	受阻后经最小边界方案打通	作者构造期事务外临时写入被守卫拒绝，原调用者未定位；改以固定 WRN 离线最小运行边界完成推理
按类别与空间标签的候选生成工具	仅设计	11-05 完成需求核对与设计，未开发、未生成

十、工程资产

这部分是“下一个接手的人能直接用”的东西。

资产	内容	位置
参数化模拟器	亮暗 × Mura 式 / 线状，几何与强度全可请求，输出请求区 / 实际残差 / 有效标签	实验/弱缺陷 `Demo/synthesis.py`、`controlled_generation/render.py`
标签核验链	区域外残差为 0、能量比对上理论值、float32 舍入级误差	各分支共用
原生分辨率评价管线	256 窗 stride128、去重尾窗、补边剔除、重叠 FP32 等权拼回	`pretrained_segmentation/native_inference.py`
精确全局像素 AP	双 uint32 计数表、ties 整体处理、与 sklearn 交叉核验	`fewshot_synthetic/metrics.exact_ap`
配对对照协议	A / B 共用正常槽与真实异常槽，仅干预槽不同，可扩三臂	`pretrained_synthetic_pairing/`、`fewshot_synthetic/`
响应测量与拟合包	输入构造、唯一化、评分、CPU 响应提取、六候选拟合、留出准备	`mura_capability/`
只读核验层	每分支独立 verify 入口，只核身份与分母，不重算指标	各分支 `cli.py` / 模块
隔离环境	`.venv`、`.venv-pretrained-seg`、`.venv-ssn`	互不污染

最可复用的是**响应测量包**：它不训练、不改权重，只做推理与统计，执行门槛比训练低一个量级，换检测器基本只需换一行加载。

十一、边界与不可引用表述

11.1 每条结论必须带的边界

结论	可以怎么说	必须同时说
模拟器有效	24 个预定请求全部有效，区域外零改动	数字外观扰动，非器件物理模型；不证明逼真
共享留出高分	G1 在共享渲染器域内 AP 99.0349%	同渲染器域、20 个相关背景、单种子；不是屏幕效果
两轮配对	平均 +1.75 / +0.78 个百分点	方向不一致、有误报代价、n=3 不是置信区间、组成混杂
响应测量	幅度—响应单调，负对照干净	固定刺激网格、60 背景、单检测器；不是真实检出率
六个拟合	全部收敛，p0 已冻结	拟合诊断不是留出成绩；留出未评
SSN	特征 AP 99.9156%，gate=false	同池拟合；分类门槛是本项目自加
真实参考生成	三版素材核验完成	生成请求 0，没有神经输出，不能判断算法效果

11.2 明确撤回的表述

10 月 28 日的独立核查（1431 个原刺激、1107 条硬边配对、2806 份旧来源文件 hash 前后未变）撤回了四条此前过强的推断，本材料全部按修订后口径：

1. ~~“缺陷整体落在可靠检出区内（8.21 > 4.58）”~~ → 探针全图背景均值与真实缺陷局部环带口径不一致，不能直接比较；
2. ~~“a90/95 可靠界成立”~~ → 旧值为 a90 重采样的下侧分位，修订后仍只是近似；
3. ~~“spot 是尺度门槛导致的漏检机制”~~ → 只保留该配置下的观察，机制未获实验支持；
4. ~~“补样本对此无效、分辨率已排除”~~ → 降为特定设定下的观察，不能外推。

保留这四条撤回记录，是因为它们本身就是成果：**测量定义和对照条件会直接改变结论强度**，这一点比结论本身更值得带进下一阶段。

11.3 三个容易混的 0.5

- GT 插值用的 0.5（特征标签口径）；
- 作者截断 L1 的 th=0.5（分割 logit 间隔）；
- 本项目分类 sigmoid 0.5（独立工程门槛）。

三者不可互换。本文凡出现“0.5”必须指明是哪一个。

十二、结论与下一步

12.1 三条结论

1. **可交付的是一条“可控输入 + 可核验标签 + 可区分口径的评价管线”，不是检测提升方案。** 模拟器、响应测量包、配对协议都能被下一个项目直接复用。

2. **“合成缺陷补样本能提升真实检测”这一命题，在现有两个域、两种监督设定、两轮配对下没有拿到稳定收益。** 平均为正但方向不一致，效应量小于初始化噪声，当前应表述为“不可检测”而非“无效”。
3. **把问题换成“检测器对什么有反应”之后，第一次拿到了可重复、可核验、带负对照的量化响应。** 这是本项目方法上最扎实的一块，也是唯一一块做完了完整分母与独立核验的。

12.2 未完成项

- 独立新屏幕数据的验证（目前只有 AnoLCD 与 KSDD2 两个公开域）；
- D_hold60 实际评分与六候选的留出比较（约 3.1 小时，单检测器）；
- 参考条件神经生成（卡在素材，不在算法）；
- 类别 + 空间标签候选工具的实现（仅设计）；
- 探针的 v2 测量协议与 patchsize 单因素对照。

12.3 两条分叉，取决于投入方向

分叉 A：优先“能交出去的候选生成工具”。

依据是 11-05 已完成的需求核对与设计：两类外观、类别与区域条件、固定条件抽卡、专家保留 / 拒绝、导出背景＋合成图＋类别＋区域＋残差＋参数＋种子。不依赖训练，工作量集中在工程与可用性，风险主要在“专家是否认可真实性”这个无法用代码验收的点上。

分叉 B：优先“检测性能改进”。

需要先回答两个前置问题：能否拿到独立于现有两个公开域的新屏幕采集数据；能拿到多少张真实异常。按当前 n=3、SD≈1.3 的离散度，1 个百分点级别的效应对应约 13 对实验，资源量级需要提前确认，否则会重复这次“效应小于噪声”的结果。

分叉 C（成本最低，建议先做）：把 D_hold60 跑完。

它是唯一能把“SEMU 代理刻度到底有没有预测用途”这个问题结掉的一步，耗时约 3.1 小时，不涉及训练、不涉及新数据。

12.4 三个待确认的问题

1. 下一阶段更需要“可用的候选生成工具”还是“检测性能改进”？
2. 是否有可用于验证的新屏幕采集数据？规模与标注条件如何？
3. 本材料是否需要另出一版面向外部（客户 / 评审）的精简版本，以及其中哪些结论可以对外？

附录 A　成果台账

#	分支	主要数字	评价池关系	状态
1	公开调研	22 节，含数据适用性与路线比较	—	完成
2	leather 基线	AUROC 1.0；检出 92/92；误报 21/32；像素 AP 46.70%	真实留出（单类别）	完成
3	校准稳定性	m=8/16/32/48 跨度 0.482 / 0.258 / 0.069 / 0；FP 均 4/48	同池方法研究	完成
4	AnoLCD 定位	PatchCore AP 85.83% / AUROC 90.86%；DRAEM-A 13.98% / 49.95%；B 15.64% / 50.37%	真实留出（历史已见）	完成
5	可控生成 G0/G1	55.1564% / 99.0349%（0.04）；11.7830% / 93.0047%（0.02）	同渲染器域	完成
6	真实参考驱动	v3 24 位置 3 通过；生成请求 0	未进入生成	暂停
7	KSDD2 随机初始化	+0.9710 / +5.4744 / −1.1916；均值 +1.7513，SD 3.4008	真实留出（探索性）	完成
8	预训练单头配对	−0.4282 / +2.1128 / +0.6467；均值 +0.7771，SD 1.2755	真实留出（探索性）	完成
9	SSN 严格 R5	特征 AP 99.9156%；FP 10/16；gate=false	同池拟合	冻结
10	受控探针主线	1431 刺激、1107 配对核查；四条强推断撤回	诊断 / 审计	收束
11	D_fit 响应测量	7560 请求；联合报警 41.10%；幅度 0→95.28%	固定刺激网格	完成
12	六候选拟合	6/6 收敛；p0=0.410979	拟合池诊断	完成
13	D_hold60	7116 唯一输入；run 未执行	背景留出	准备完成
14	候选工具设计	需求与设计完成，未开发	—	设计

附录 B　数字来源

内容	源文件
模拟与共享留出	报告/可控 Mura 与线状缺陷模拟两周研究报告.md；results/controlled_generation/shared_holdout_v1/
阶段总结与修订表	报告/项目阶段总结报告.md；报告/项目成果总览与成文建议.md
两轮配对训练	报告/少样本真实工业缺陷合成训练研究报告.md；报告/预训练单头分割可控合成配对实验研究报告.md
SSN	报告/预训练单头分割严格 R5 基线研究报告.md；results/ssn_baseline/kssd2_r5_v1/
探针与修订	报告/受控探针检测器能力标定核查修订报告.md
D_fit 响应	报告/PatchCore 独立 D_fit 缓存响应后处理结果.md；results/mura_capability/week1_v1/patchcore_fit_response_v1/
六候选拟合	报告/PatchCore_D_fit 统计拟合准备与人工运行说明.md；.../patchcore_fit_analysis_v1/run/models.json
D_hold60 准备	报告/PatchCore_D_hold60 独立只读评分准备与运行说明.md；.../patchcore_hold_scoring_v1/preparation/
候选工具设计	计划/可控缺陷模拟与标签工具设计.md；报告/按缺陷类别与空间标签控制生成_方向调研.md